

Anexo D · Hoja de Ruta del grupo

Este es el pasaporte del equipo. Sin sello no hay avance. Sin la firma de los cinco corredores no se recibe la cartulina.

Firma consultora (nombre del grupo): Grupo Constructora 1

Hora de inicio: 1:25 Hora de finalización: 3:43 Tiempo total: _____

Momento	Corredor titular	Hora de entrega	Checkpoint	Sello	Penalización
1. Sala de servidores	Sara Lora Ferro	1:40 pm			-0.5
2. Datos sucios	Antoine .	3:22 pm 3:29 p.m.			-0.1 -0.1
3. El tablero miente	Juan MA / Sugo	3:22 pm			-0.3
4. La reunión caótica	Jessica Gel	3:35 p.m.			
5. El muro	Lina Bautista	3:43 p.m.			

Firmas de los cinco corredores:

1	2	3	4	5
Sara Ferro		x due	Jessica Gel	

Momento 1 · Sala de servidores

10 minutos | Corredor 1 | 15 puntos | Insumo: M1_inventario_fuentes.csv

Entraste a la sala de servidores de VeloBog y encontraste tres tableros desordenados. Para abrir la puerta del siguiente cuarto hay que resolverlos.

1.1 Ordena el flujo · 4 puntos

Numera de 1 a 7 según el ciclo de vida del dato:

Etapas	N°	Etapas	N°
Visualización y consumo	2	Modelado y análisis	6
Almacenamiento en el data warehouse	3	Generación del dato en el origen	1
Ingesta desde las fuentes	4	Transformación y limpieza	5
Gobierno y monitoreo continuo	7		

1.2 Empareja el rol con la frase · 4 puntos

Rol	Letra + número	Frase que diría en una reunión
A. Ingeniero de datos ✓	D+1	1. «Necesito que el reporte de ocupación esté listo cada lunes a las 7 a.m.»
B. Analista de datos ✓	C+2	2. «El pipeline se cayó anoche, la partición del 14 no cargó.»
C. Científico de datos ✓	A+3	3. «Voy a entrenar un modelo para predecir la demanda por estación.»
D. Stakeholder de negocio	B+4	4. «Con estos gráficos se ve que los martes cae el uso un 12 %.»

1.3 Verdadero o falso, con justificación de una línea · 4 puntos

Sin justificación la respuesta no puntúa.

Afirmación	V/F	Justificación
a. Un dato con formato correcto es automáticamente un dato de calidad.	V	Permite el manejo correcto.
b. El EDA se hace después de tener el modelo entrenado.	F	La EDA va después de la ETL
c. En un pipeline ELT la transformación ocurre dentro del sistema de destino.	F	La Transformación se hace en el sistema base. inicial
d. Los requerimientos no funcionales son opcionales porque no describen funciones del sistema.	V	Los funcionales son quienes me describen el sistema.

1.4 Reto de lógica · 3 puntos

Abre M1_inventario_fuentes.csv. Hay tres fuentes: App móvil, Candados IoT y Excel de Operaciones. Dos celdas están marcadas con «?» y debes deducirlas con estas pistas:

- La fuente que actualiza en tiempo real no es la que tiene errores de digitación.

Momento 2 · Datos sucios

18 minutos | Corredor 2 | 25 puntos | Insumo: M2_viajes_agosto.csv (Anexo A)

El equipo de la app te pasó una muestra del archivo viajes_agosto.csv. La coordinadora jura que está limpio. No lo está.

2.1 Auditoría de calidad · 10 puntos

Revisa el Anexo A e identifica mínimo ocho problemas de calidad distintos. Para cada uno completa una fila:

#	Fila / columna	Problema detectado	Tipo	Regla de transformación propuesta
1	F1	escritura del costo (\$35w)	formato	Todos costos debe se escribir 3.500,00 12.509,00
2	F2	escritura del tipo	formato	Todo debe se escribir en minuscula sin acentos
3	F10	caracter especial (@)	valor atípico	No debe ser permitido escribir caracteres
4	F6	ph costo (= 0)	inconsistencia	Debe ser de 3500,00
5	F3	valor negativa de tiempo	violación regla	Debemos tener valor absoluto
6	F7	No hay id_usuario digitado	violación	No podría escribir otro sin el id_usuario
7	F11	Pb de horas (12h o 24h)	formato	Debemos elegir un tipo de hora (12 horas)
8	F7	hay celdas nulas	nulo	debemos escribir ND si no hay nada

Tipos válidos: duplicado · nulo · formato · inconsistencia · valor atípico · violación de regla de negocio.

Ojo: dos problemas del anexo no se ven mirando una sola celda. Se detectan comparando columnas entre sí.

2.2 Diseño del pipeline · 9 puntos

Escribe el pipeline en pseudocódigo o SQL, con las tres fases rotuladas:

- [E] **EXTRACT**: de dónde, con qué frecuencia y cómo detectas registros nuevos.
- [T] **TRANSFORM**: mínimo cinco operaciones, en el orden correcto.
- [L] **LOAD**: destino, granularidad (¿una fila por qué cosa?) y estrategia de carga.

Debes justificar por qué la deduplicación va antes o después de la conversión de tipos.

2.3 Decisión de ingeniería · 6 puntos

Responde y argumenta en máximo cuatro renglones cada una:

- a. Encontraste 47 viajes con duración negativa. Tienes tres opciones: eliminar, imputar o cuarentena. ¿Cuál eliges y cuál es el costo de las otras dos?
- b. El campo estación de origen viene escrito de seis formas distintas para la misma estación. ¿Lo resuelves con normalización de texto o con una tabla maestra de estaciones? Sustenta.

Entregable: tabla de auditoría más pipeline escrito.

- 1) minusculas por tipos
- 2) Duplicacion elimina
- 3) Solo 1 tipo de hora
- 4) ND por celdas nulas
- 5) ND por edad absurdo

Anexo A · Muestra de M2_viajes_agosto.csv

id_viaje	id_usuario	estacion_origen	estacion_destino	fecha_inicio	fecha_fin	duracion_min	costo	edad_usuario	tipo_bici
1001	U-0231	Chapinero	Usaquén	2026-08-03 07:12	2026-08-03 07:41	29	\$3.500	28	mecanica
1002	U-0231	chapinero	Usaquen	03/08/2026 7:12	2026-08-03 07:41	29	3500	28	mecánica
1003	U-0987	CHAPINERO	Suba	2026-08-03 08:05	2026-08-03 07:50	-15	3.500	31	electronica
1004		Teusaquillo	Teusaquillo	2026-08-04 18:22	2026-08-04 18:23	1	0	45	mecanica
1005	U-0442	Kennedy	Chapinero	2026-08-05 06:58	2026-08-05 09:44	166	12500	199	electronica
1006	U-0442	Kennedy	Chapinero	2026-08-05 06:58	2026-08-05 09:44	166	12500	199	electronica
1007	U-1120	Suba	NULL	2026-08-06 12:30				22	mecanica
1008	U-0075	Usaquén	Chapinero	2026-08-07 19:10	2026-08-07 19:33	23	3500	ND	ELECTRICA
1009	U-0075	Usaquén	Chapinero	2026-08-07 19:10	2026-08-07 19:33	23	3.500		electronica
1010	U-0663	Chapinero	Kennedy	2026-13-08 14:00	2026-08-08 14:35	35	3500	34	mecanica
1011	U-0663	Kennedy	Kennedy	2026-08-09 05:00	2026-08-09 21:00	960	3500	34	mecanica
1012	U-0301	Fontibón	Suba	2026-08-10 16:40	2026-08-10 17:05	25	-3500	17	electronica

Reglas de negocio vigentes en VeloBog

- La edad mínima para usar el servicio es 18 años.
- La tarifa base es \$3.500 por viaje de hasta 30 minutos; sobre eso, \$50 por minuto adicional.
- Ningún viaje puede durar más de 8 horas: a las 8 h el sistema reporta bicicleta perdida.
- id_viaje es único. id_usuario es obligatorio.

Momento 3 · El tablero mente

15 minutos | Corredor 3 | 20 puntos | Insumos: los tres archivos M3 (Anexo B)

El gerente muestra en el comité un tablero que dice: «el viaje promedio dura 34 minutos, vamos excelente». Tú sospechas.

3.1 Estadística que decide · 8 puntos

- a. Calcula la media y la mediana de la duración con los datos del Anexo B.1. Muestra el procedimiento. ✓
- b. Explica en dos renglones por qué difieren tanto y cuál de las dos debe ir en el tablero del gerente. ✓
- c. Aplica la regla del rango intercuartílico: identifica qué valores quedan fuera de $[Q1 - 1,5 \cdot IQR ; Q3 + 1,5 \cdot IQR]$. ✓

3.2 Lectura de distribución y nulos · 6 puntos

- a. La columna edad_usuario tiene 18 % de nulos y todos pertenecen a usuarios registrados antes de 2023. ¿Ese nulo es aleatorio o sistemático? ¿Qué implica para tu análisis?
- b. Observa la tabla de viajes por franja horaria. Describe la forma de la distribución y da una hipótesis de negocio que la explique.

3.3 De hallazgo a acción · 6 puntos

Escribe tres hallazgos en el formato exigido por la firma:

Hallazgo	Evidencia (cifra)	Riesgo o pregunta que abre	Acción recomendada
1.	0	PARTE De Atras!	→
2.			
3.			

Trampa: al menos uno de tus hallazgos debe advertir que el dato todavía no permite concluir algo, y explicar qué dato faltaría.

Entregable: cálculos más tabla de hallazgos.

A
3.1 B R // debería ser la mediana en base a que estamos calculando la mediana sería 17 la mitad de 34 min del tiempo estipulado
3.2. B // Un rango entre las 00-05 por la hora hay mucho menos actividad en los viajes debido a las horas mostradas y las mas frecuentadas serian 06-08 y 18-20 debido a que aumentan debido a la disponibilidad de la gente, mejor conocido como hora mas transitada, esto hace mas viajes.
3.3 A B // El dato # 18 es Aleatorio debido a que en el sistema lo introduce el # % del usuario por lo tanto sería un dato nulo por el usuario registrado.

Anexo B · Datos para el EDA

B.1 · M3_duraciones_muestra.csv — duración en minutos de 15 viajes

8 · 11 · 12 · 12 · 14 · 15 · 17 · 18 · 20 · 22 · 24 · 27 · 31 · 180 · 402

B.2 · M3_viajes_por_franja.csv — viajes por franja horaria en agosto

Franja	Viajes
00-05	210
06-08	8.940
09-11	2.130
12-14	3.480
15-17	2.960
18-20	9.610
21-23	1.150

B.3 · M3_completitud_campos.csv — porcentaje de nulos

Campo	% nulos	Observación del equipo
id_usuario	3 %	Concentrados en registros del Excel de Operaciones
estacion_destino	11 %	El 100 % ocurre entre 18:00 y 20:00 en Suba y Kennedy
duracion_min	11 %	Coinciden fila a fila con los nulos de estacion_destino
edad_usuario	18 %	Todos pertenecen a usuarios registrados antes de 2023
costo	0 %	Sin nulos

B3//

Hallazgos

En el punto 1 los valores varían entre el 2 y 402

Ultimo dato pt B3

En el punto B2 en la franja los datos desvarían mucho (ver B1)

evidencia

los meses de 2001 y 2009 salen bajos y en 2015 altos

en costos hay 0 y sin datos

lo que es el número de edad usuario de viajes de 18 años y 40 años

se debe a que el resultado

Pregunta que abre

Porque tanta Varianza de tiempo

Porque en esta cifra No hay 1 de los nulos

la cifra mantiene los valores de los nulos

NO coherente y MANERA que desvaría el resultado

Acción recomendada

tomar el dato nuevamente

Ajustar el porcentaje para tomar el dato correctamente corrigiendo el dato para que sea exacto

ver el Delta en la escala de viajes y de usuarios

que NO coincide con las escalas de las demás

Momento 4 · La reunión caótica

17 minutos | Corredor 4 | 25 puntos | Insumo: M4_transcripcion_kickoff.csv (Anexo C)

Te tocó ser el único de tu equipo en la reunión de kickoff. Nadie tomó nota ordenada. Solo quedó la transcripción. Con eso hay que arrancar el sprint.

4.1 Mapa de actores · 6 puntos

Clasifica a todos los actores que aparecen en la transcripción:

Actor	¿Stakeholder, usuario final o ambos?	Interés principal	Influencia
Gerente General	Stakeholder	Ver viajes y facturación	Alta
Coor. Operaciones	ambos	ver disponibilidad bicicletas, actualización historial viaje usuario	Alta
Líder Producto	usuario final	Usar Mongo DB	baja
Desarrollador Backend	usuario final	aplicación funcional	Alta
Biciusuarios	usuario final	disponibilidad bici	baja
Ciudadanos	usuario final	aplicación funcional	baja

Además: identifica al actor que fue mencionado pero no estuvo en la reunión y explica qué riesgo genera esa ausencia. El actor mencionado que no estuvo son los biciusuarios y ciudadanos y el riesgo que genera es que al no estar en la reunión no pueden decir sus problemas, ni historias de usuario.

4.2 Extracción de requerimientos · 8 puntos

- Mínimo 4 requerimientos funcionales, redactados como «El sistema debe permitir...».
- Mínimo 3 requerimientos no funcionales, indicando la categoría: rendimiento, seguridad, usabilidad, disponibilidad o escalabilidad.
- Una frase de la transcripción que NO es un requerimiento —una queja, un deseo vago o una solución impuesta— reescrita como requerimiento verificable.

4.3 Historias de usuario · 11 puntos

Redacta tres historias de usuario, cada una para un rol distinto, en este formato:

Estructura	Contenido
Como <rol> quiero <acción> para <beneficio de negocio>	Como gerente general quiero consultar el historial de viajes y la facturación para ver el estado del negocio
Criterios de aceptación (Gherkin): Dado... / Cuando... / Entonces...	Dado el caso de viajes cuando son los datos de los biciusuarios cuando no me los da
Prioridad MoSCoW y justificación en una línea	

- Cada historia debe tener mínimo dos criterios de aceptación.
- Una de las tres debe ser una historia técnica del equipo de datos, no de la app.

Entregable: mapa de actores, lista de requerimientos funcionales y no funcionales, y tres historias.

RF

1. Consultar número de viajes por día
2. Consultar disponibilidad de bicicletas en tiempo Real
3. Consultar facturación por día
4. Consultar historial de viajes del usuario.
5. Registrar Usuario

RNF.

1. Rendimiento: El sistema debe demorarse menos de 3 min.
 2. Seguridad: El sistema debe permitir consultar el historial de viajes de un usuario solo al equipo del líder de producto.
 3. Escalabilidad: El sistema debe permitir ingresar muchos datos por la ampliación de la red.
- Frase: Realizamos toda la operación del día.

HU.

Nombre:

1. Como gerente general quiero consultar el número de viajes y la facturación para ver rendimientos y posibles mejoras del negocio.
 1. El gerente debe ingresar el id Ruta para poder consultar el número de viajes y la facturación de la ruta.
 2. Dado que el gerente ingresa un id Ruta inexistente el sistema debe mostrar Ruta no encontrada.
 - 3.

Prioridad: Crítica, porque con ese requerimiento se pueden tomar decisiones de negocio.

2. Como Coordinador de operaciones quiero consultar las estaciones que se quedan sin bicicletas antes de las 8 am criterios para enviar el camión a reponer y no haya desabastecimiento.
 1. El Coordinador debe ingresar su id usuario para consultar la disponibilidad de bicicletas por estación.
 2. El Coordinador debe ingresar un id Estación si desea consultar una la disponibilidad de una estación.

Prioridad: Crítica, porque es importante para mantener el negocio y no tener problemas de abastecimiento.

3. Como líder de producto quiero consultar el historial de viajes de un usuario cuando escriben a soporte para solucionar las PR.
 1. Como líder de equipo debo ingresar un id usuario para acceder al historial.
 2. Dado que una persona externa ingresa un id usuario no válido el sistema debe dar el mensaje id usuario inválido.


Prioridad Media, las Solución de preguntas de soporte puede esperar ya que primero se debe tener un sistema funcional.


Anexo C · Transcripción de la reunión de kickoff

Archivo M4_transcripcion_kickoff.csv

#	Actor	Intervención
1	Marcela · Gerente General	Necesito ver en una sola pantalla cuántos viajes hacemos por día y cuánto facturamos. Ayer el inversionista me preguntó y no supe qué decir. Y por favor que cargue rápido, no como el sistema anterior que se demoraba tres minutos. <i>13 min</i>
2	Julián · Coordinador de Operaciones	Lo mío es distinto. Yo necesito saber qué estaciones se quedan sin bicicletas antes de las 8 de la mañana, para mandar el camión a reponer. Si me avisa una hora antes, perfecto.
3	Julián · Coordinador de Operaciones	Ah, y yo actualizo un Excel todos los días a mano... ojalá no me toque seguir haciéndolo.
4	Daniela · Líder de Producto	Los usuarios se quejan en las reseñas de que la app no muestra <u>bicicletas disponibles en tiempo real</u> .
5	Daniela · Líder de Producto	También quiero poder consultar el <u>historial de viajes de un usuario</u> cuando escriben a soporte, pero solo yo y el <u>equipo de soporte</u> deberíamos ver eso, ahí hay datos personales.
6	Andrés · Desarrollador backend	Yo les digo desde ya: háganlo en MongoDB, punto. Es lo que yo sé usar. <i>NF</i>
7	Marcela · Gerente General	Otra cosa, la semana pasada se cayó el sistema un domingo y perdimos toda la operación del día. Eso no puede volver a pasar. <i>Oreja</i>
8	Julián · Coordinador de Operaciones	Y a mí me sirve poder <u>descargar un archivo con los viajes del mes</u> para pasárselo al contador.
9	Daniela · Líder de Producto	Ojo que el mes entrante entramos en Medellín y en Cali. Vamos a triplicar el <u>volumen de datos</u> . <i>NF</i>
10	Marcela · Gerente General	Ah, y hablando de eso... el área jurídica dijo algo sobre protección de datos personales de los usuarios, pero no alcanzaron a venir hoy. Después les cuento.
11	Julián · Coordinador de Operaciones	Los <u>usuarios de la bici</u> , los <u>ciudadanos</u> , ellos qué... bueno, ellos solo quieren que la bici esté ahí y que la app no se caiga.

Usuario
 Bicicleta
 Estacion
 viaje
 mantenimiento
 Tarifa





Grupo 1

Respuesta pregunta final momento 1

la única fuente confiable para saber a que hora terminó un viaje pero que exige una deduplicacion obligatoria es la planilla que la coordinadora diligencia manualmente al final del día, ya que es la que cuenta con el registro de fin de viaje y adicional no reintenta el envio de señal a diferencia de los candados IoT

MOMENTO 2

2.2

Va despues porque estandarizar los datos garantiza que valores equivalentes de distintas formas sean reconocidos correctamente como duplicados idénticos

2.3

a) imputar por conservar el volumen de datos. El costo de eliminar es perder informacion y el de cuarentena es retrasar el procesamiento con análisis manuales.

b) Debemos resolver con una tabla maestra de estaciones porque seis formas distintas incluyen abreviaturas, sinonimos etc... que la normalizacion algoritmica no puede asociar con seguridad. Esta tabla permite un mapeo que garantiza la integridad de los datos a variaciones semanticas complejas.

Momento 5

Entre el UML Y el mapa conceptual pasamos de entidades a clases también de lamos la visibilidad en el uml tipo de dato y método

